

Détection de Fraude dans les Opérations Bancaires

Rapport d'analyse et de modélisation Machine Learning

Auteur	Junior
Dataset	Credit Card Fraud Detection (Kaggle / ULB)
Date	Juin 2026
Technologie	Python · scikit-learn · XGBoost · imbalanced-learn

1. Introduction

La fraude bancaire représente une menace croissante pour les institutions financières et leurs clients. Avec l'essor des paiements numériques, les fraudeurs développent des stratégies de plus en plus sophistiquées pour contourner les systèmes de sécurité traditionnels.

Ce projet vise à construire un système de détection automatique de fraudes par apprentissage automatique (Machine Learning), capable d'identifier les transactions suspectes en temps quasi-réel. Nous utilisons le dataset public *Credit Card Fraud Detection* mis à disposition par l'Université Libre de Bruxelles (ULB).

2. Description du Dataset

Le dataset contient des transactions par carte de crédit effectuées en septembre 2013 par des titulaires européens. Il couvre deux jours de transactions.

Caractéristique	Valeur
Nombre de transactions	284 807
Transactions frauduleuses	492 (0,17 %)
Transactions normales	284 315 (99,83 %)
Nombre de variables	31 (Time, V1–V28, Amount, Class)
Valeurs manquantes	Aucune
Variables V1–V28	Composantes PCA (anonymisées)

3. Exploration des Données

L'analyse exploratoire a permis de mettre en évidence deux caractéristiques essentielles du dataset : un fort déséquilibre entre les classes et une différence notable dans la distribution des montants.

3.1 Distribution des montants

Le graphique ci-dessous compare la distribution des montants des transactions normales (en bleu) et frauduleuses (en rouge). On observe que :

- Les transactions normales atteignent jusqu'à 25 000 €, avec une concentration entre 0 et 1 000 €.
- Les transactions frauduleuses restent majoritairement inférieures à 500 €, ce qui indique que les fraudeurs préfèrent des petites sommes pour éviter la détection.




Figure 1 – Distribution des montants par classe

3.2 Matrice de corrélation

La matrice de corrélation révèle que les variables V1 à V28 (issues d'une ACP) sont quasi-indépendantes entre elles — ce qui est idéal pour les algorithmes de ML. Seules quelques variables (V2, V4, V11) présentent une corrélation notable avec la variable cible **Class**.




Figure 2 – Matrice de corrélation

4. Prétraitement des Données

Avant d'entraîner les modèles, plusieurs étapes de prétraitement ont été appliquées :

Étape	Description
-------	-------------

Normalisation	StandardScaler appliqué aux variables Time et Amount
Division train/test	70 % entraînement — 30 % test (stratifié)
Gestion du déséquilibre	SMOTE : génération synthétique d'exemples frauduleux
Résultat après SMOTE	199 020 normales vs 199 020 fraudes (équilibré)

5. Modèles de Machine Learning

Cinq modèles ont été entraînés et comparés. Pour chaque modèle, les métriques principales sont la précision, le recall et le F1-score sur la classe fraude (Class=1).

5.1 Tableau comparatif

Modèle	Précision	Recall	F1-score	Fausses alarmes	AUC
Random Forest Base	0.87	0.79	0.83	18	0.954
XGBoost	0.75	0.80	0.78	39	0.974
Random Forest Optimisé	0.78	0.80	0.79	33	0.964
Logistic Regression	0.06	0.88	0.12	1919	—
SVM (LinearSVC)	0.06	0.87	0.11	2008	—

5.2 Matrices de confusion

Les matrices de confusion permettent de visualiser les vrais positifs (fraudes correctement détectées), les faux positifs (fausses alarmes) et les faux négatifs (fraudes manquées) pour chaque modèle.




Figure 3 – Matrices de confusion des trois meilleurs modèles

5.3 Courbe ROC

La courbe ROC (Receiver Operating Characteristic) mesure la capacité du modèle à distinguer les fraudes des transactions normales. L'AUC (Area Under the Curve) est d'autant meilleure qu'elle est proche de 1.




Figure 4 – Courbe ROC et AUC des trois meilleurs modèles

6. Interprétation et Conclusion

6.1 Analyse des résultats

Les résultats montrent clairement que les modèles ensemblistes (Random Forest et XGBoost) surpassent largement les modèles linéaires (Régression Logistique et SVM) pour ce problème de détection de fraude.

La Régression Logistique et le SVM obtiennent certes un recall élevé (88 % et 87 %) mais génèrent un nombre catastrophique de fausses alarmes (respectivement 1 919 et 2 008). En pratique, cela signifierait bloquer des milliers de transactions légitimes par jour, ce qui est inacceptable en production.

6.2 Meilleur modèle

XGBoost est le modèle recommandé avec un AUC de 0,974 — le plus élevé parmi tous les modèles testés. Il offre le meilleur compromis entre la détection des fraudes (recall = 0,80) et la limitation des fausses alarmes (39 seulement).

Le Random Forest de base reste une excellente alternative avec le meilleur F1-score (0,83) et le moins de fausses alarmes (18), au prix d'un AUC légèrement inférieur.

6.3 Perspectives d'amélioration

Plusieurs pistes peuvent être explorées pour améliorer encore les performances :

- Optimisation des hyperparamètres XGBoost avec Pipeline + RFECV
- Ajout de nouvelles variables (feature engineering)
- Utilisation de réseaux de neurones (LSTM, Autoencoder) pour détecter des anomalies
- Déploiement du modèle via une API REST (Flask/FastAPI) ou une interface Streamlit
- Mise en place d'un système de réentraînement automatique (drift detection)

7. Conclusion

Ce projet démontre l'efficacité des algorithmes de Machine Learning pour la détection de fraudes bancaires. Grâce à une méthodologie rigoureuse — prétraitement des données, gestion du déséquilibre par SMOTE, comparaison de cinq modèles et optimisation des hyperparamètres — nous avons obtenu un système capable de détecter 80 % des fraudes avec une très faible proportion de fausses alarmes.

XGBoost, avec un AUC de 0,974, est le modèle retenu pour un éventuel déploiement en production. Ce travail constitue une base solide pour un système de surveillance des transactions bancaires en temps réel.

